

선형대수학팀

3팀
이재현
김규범
김민지
이정우
조혜현

INDEX

1. 선형대수의 기하학적 접근
2. 기하학적 접근의 응용
3. 행렬의 분해/인수화
4. 응용편

1

선형대수의 기하학적 접근

노름(Norms)

노름(Norms)

벡터의 "크기"

$$\|x\| = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2}$$

노름(Norms)



노름의 종류 중 하나!

노름(Norms)

벡터의 "크기"

$$\|x\| = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2}$$

노름의 공식



$$L_p = \sqrt[p]{|x_1|^p + |x_2|^p + \cdots + |x_n|^p}$$

p 는 노름의 차수

ex. p 가 1이면 L1 Norm, p 가 2이면 L2 Norm

노름의 종류

✓ 맨허튼 노름(Manhattan Norm)

$$L_1 = |x_1| + |x_2| + \cdots + |x_n|$$

좌표평면에서 각 좌표축을 따라 움직이는 거리

✓ 유클리드 노름(Euclidean Norm)

$$L_2 = \sqrt{|x_1|^2 + |x_2|^2 \dots + |x_n|^2}$$

원점에서 x 라는 벡터에 연결된 직선 거리

내적(Inner Products)

내적(Inner Products)

각 성분끼리의 곱의 합

$x = (x_1, x_2, \dots, x_n), y = (y_1, y_2, \dots, y_n)$ 일 때,

$$x \bullet y = x_1 y_1 + x_2 y_2 + \dots + x_n y_n$$

내적(Inner Product)



두 벡터의 내적을

행렬의 곱연산으로 나타낼 수 있음

각 성분끼리의 곱의 합

$$x \cdot y = x^T y$$


크기가 같은
두 벡터 중
앞 벡터를

Transpose!

 $x = (x_1, x_2, \dots, x_n), y = (y_1, y_2, \dots, y_n)$ 일 때,


$$\begin{bmatrix} x_1 & x_2 & \dots & x_n \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = x_1 y_1 + x_2 y_2 + \dots + x_n y_n = x_1 y_1 + x_2 y_2 + \dots + x_n y_n$$

내적의 기하학적 해석



“ 벡터 x 를 벡터 y 에 투영시켰을 때의 크기
×
벡터 y 의 크기 ”

내적의 기하학적 해석



$$x \cdot y = \|x\| \|y\| \cos\theta$$

각도(Angle)

각도(Angle)

두 벡터 사이 각도

두 벡터가 어떤 모양을 가지고 있는지 아는게 필수적



$$\cos\theta = \frac{x \cdot y}{\|x\|\|y\|} \leftrightarrow \theta = \cos^{-1}\left(\frac{x \cdot y}{\|x\|\|y\|}\right)$$

$x \cdot y, \|x\|, \|y\|$ 은 벡터의 성분을 알고 있으면 구할 수 있음

직교성(Orthogonality)

직교(Orthogonal)

두 벡터 사이의 각도가 **90°(직각)**

$$\cos\theta = \frac{x \cdot y}{\|x\|\|y\|} \text{에서 } \theta = 90^\circ \text{이면}$$

$$\text{" } x \cdot y = 0 \text{ "}$$

직교성(Orthogonality)



정규직교(Orthonormal)

직교(Orthogonal)

두 벡터 사이의 각도가 90° (직각)

$$x \cdot y = 0$$

&



$$\cos \theta = \frac{x \cdot y}{\|x\| \|y\|} \text{ 에서 } \theta = 90 \text{ 이면}$$

$$\|x\| = \|y\| = 1$$

$$x \cdot y = 0$$

직교성(Orthogonality)

직교행렬(Orthogonal Matrix)

" $AA^T = A^T A = I$ ", " $A^T = A^{-1}$ "를 만족하는 정사각행렬
열벡터들이 **정규직교**



직교행렬을 이용한 선형 변환은
input vector x 의 크기가 변하지 않음

직교성(Orthogonality)

$$\|Ax\|^2 = (Ax)^T (Ax) = x^T A^T A x$$

직교행렬 (Orthogonal Matrix)을 만족하는 정방행렬
 $A^T A = I$ 일 때 $x^T A^T A x = x^T I x = x^T x = \|x\|^2$ 를 만족함
 열벡터들이 정규직교



직교행렬을 이용한 선형 변환은
 input vector x 의 크기가 변하지 않음

집합의 직교성



두 벡터의 직교성을 집합에 일반화

즉, 벡터들의 집합 $\{x_1, x_2, \dots, x_n\}$ 에서 각 x_i 가 서로 직교하는 집합

직교집합(Orthogonal Set)

$$x_i \cdot x_j = 0, \\ \text{where } i \neq j$$

정규직교집합(Orthonormal Set)

$$x_i \cdot x_j = 0, \text{ where } i \neq j \\ \& \\ \|x_i\| = 1$$

기저의 직교성



기저 $B = \{b_1, b_2, \dots, b_n\}$ 에서 기저벡터 b_i 들이 서로 직교하는 기저

직교기저(Orthogonal Basis)

$$b_i \cdot b_j = 0, \\ \text{where } i \neq j$$

정규직교기저(Orthonormal Basis)

$$b_i \cdot b_j = 0, \text{ where } i \neq j \\ \& \\ \|b_i\| = 1$$

기저의 직교성



Standard Basis



$$\begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ \vdots \\ 0 \\ 0 \end{bmatrix}, \dots, \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \\ 1 \end{bmatrix}$$

는

직교기저(Orthogonal Basis)

정규직교기저(Orthonormal Basis)

$$b_i \cdot b_j = 0, \\ \text{where } i \neq j$$

정규직교기저!

$$b_i \cdot b_j = 0, \text{ where } i \neq j$$


&

$$\|b_i\| = 1$$

직교여공간(Orthogonal complement)

직교여공간(Orthogonal Complement)

집합 S 가 공집합이 아닌 R^n 에 속하는 벡터의 집합일 때, S 에 속하는 **모든 벡터들에 직교하는 벡터들의 집합**




2

기하학적 접근의 응용


정사영

정사영

투영이란 어떤 벡터를
다른 벡터로 옮겨 표현하는 것
이때, 직각을 이루게 하여 투영하는
것을 **정사영** 이라고함



정사영




$$Proj_b(a) \text{의 크기} = \|a\| \cos \theta = \|a\| \frac{\vec{a} \cdot \vec{b}}{\|a\| \|b\|} = \frac{\vec{a} \cdot \vec{b}}{\|b\|}$$

$$Proj_b(a) \text{의 방향} = \frac{\vec{b}}{\|b\|}$$

$$Proj_b(a) = \text{크기} \cdot \text{방향} = \frac{\vec{a} \cdot \vec{b}}{\|b\|^2} \vec{b}$$


2차원에서의 회전



θ 가 회전하고 싶은 각도일 때, 회전은

행렬 $R = \begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix}$ 을 곱함으로써 구할 수 있음

3차원에서의 회전



$$\begin{bmatrix} \cos\theta & -\sin\theta & 0 \\ \sin\theta & \cos\theta & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$$\begin{bmatrix} 1 & 0 & 0 \\ 0 & \cos\theta & -\sin\theta \\ 0 & \sin\theta & \cos\theta \end{bmatrix}$$


$$\begin{bmatrix} \cos\theta & 0 & \sin\theta \\ 0 & 1 & 0 \\ -\sin\theta & 0 & \cos\theta \end{bmatrix}$$

3차원에서의 회전은 어떤 평면을 회전하느냐에 따라
회전 방향이 달라짐!

3

행렬의 분해/인수화

행렬식(Determinant)



행렬식

- 정사각행렬이 실수에 대응되는 함수
행렬 A 에 대해 $\det(A)$ 로 나타냄
- $\det(A) = 0 \leftrightarrow A$ 의 역행렬이 존재하지 않음
- $A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$ 일 때, $\det(A) = ad - bc$

행렬식(Determinant)



Laplace Expansion

$n \times n$ 행렬의 행렬식의 계산 방법

Example

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}$$

일 때, $\det(A) = \sum_{k=1}^n (-1)^{k+j} a_{kj} \det(A_{kj})$

$$\det(A) = 1 \det \begin{bmatrix} 5 & 6 \\ 8 & 9 \end{bmatrix} - 4 \det \begin{bmatrix} 2 & 3 \\ 8 & 9 \end{bmatrix} + 7 \det \begin{bmatrix} 2 & 3 \\ 5 & 6 \end{bmatrix}$$

- 정사각행렬이 실수에 대응되는 함수

행렬의 크기를 나타내며

- $\det(A) = 0 \leftrightarrow A$ 의 역행렬이 존재하지 않음

행렬식 및 대각합

대각합(Trace)

- $A \in \mathbb{R}^{n \times n}$ 에 대해 $\text{tr}(A) = \sum_{i=1}^n a_{ii}$
- 정사각행렬 A의 대각합(trace)은 **대각성분의 합**

정사각행렬 $A = \begin{bmatrix} 1 & 3 & 2 \\ 2 & 7 & 4 \\ 1 & 5 & 2 \end{bmatrix}$ 일 때 $\text{tr}(A) = 1 + 7 + 2 = 10$

고유값과 고유벡터

고유값과 고유벡터

$A \in \mathbb{R}^{n \times n}$ 에 대해 영벡터를 제외한 $x \in \mathbb{R}^n$ 에서
 $Ax = \lambda x$ 일 때, λ 를 고유값, x 를 고유벡터라고 함

$n \times n$ 정사각행렬

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix}$$

고유벡터 ($\neq \vec{0}$)

$$A \overset{\text{고유벡터 } (\neq \vec{0})}{X} = \underset{\text{고유값}}{\lambda} \overset{\text{고유벡터 } (\neq \vec{0})}{X}$$

$$Ax = \lambda x = \lambda Ix$$

$$Ax - \lambda Ix = 0$$

$$(A - \lambda I)x = 0$$



$Ax = \lambda x$ 에서
고유벡터 x 가 존재하기 위한 조건?
고유값과 고유벡터

$(A - \lambda I)x = 0$ 에서 영벡터가 아닌 x 가 존재해야 함

만약 $(A - \lambda I)$ 의 역행렬이 존재한다면

$x = (A - \lambda I)^{-1}0$ 이 되므로 x 는 영벡터가 되어

고유벡터라고 할 수 없음

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix}$$

$$Ax = \lambda x = \lambda Ix$$

$$Ax - \lambda Ix = 0$$

이는 $\det(A - \lambda I) = 0$ 를 만족해야 함을 의미

고유값과 고유벡터

고유값과 고유벡터

$A \in \mathbb{R}^{n \times n}$ 에 대해 영벡터를 제외한 $x \in \mathbb{R}^n$ 에서
 $Ax = \lambda x$ 일 때, λ 를 고유값, x 를 고유벡터라고 함



$A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$ 일 때 고유값과 고유벡터를 구해보자

$$\det(A - \lambda I) = \begin{vmatrix} 2 - \lambda & 1 \\ 1 & 2 - \lambda \end{vmatrix} = (2 - \lambda)^2 - 1 = \lambda^2 - 4\lambda - 3 = 0$$

$\det(A - \lambda I) = 0$ 이용

$\therefore \lambda = 1 \text{ or } 3$



행렬의 분해/인수화

$\lambda = 1$ 인 경우

고유값과 고유벡터

$$(A - \lambda I)x = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = 0$$

$A \in \mathbb{R}^{n \times n}$ 에 대해 영벡터를 제외한 $x \in \mathbb{R}^n$ 에서 $Ax = \lambda x$ 일 때, λ 를 고유값, x 를 고유벡터라고 함

$$x_1 + x_2 = 0, \quad x_2 = -x_1, \quad x = x_1 \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$



고유값 $\lambda = 1$ 에 대한 고유벡터 : $x_1 \begin{pmatrix} 1 \\ -1 \end{pmatrix}$ ($x_1 \neq 0$)

$A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$ 일 때 고유값과 고유벡터를 구해보자

$$\det(A - \lambda I) = \begin{vmatrix} 2 - \lambda & 1 \\ 1 & 2 - \lambda \end{vmatrix} = (2 - \lambda)^2 - 1 = \lambda^2 - 4\lambda - 3 = 0$$

$\det(A - \lambda I) = 0$ 이용

$\therefore \lambda = 1 \text{ or } 3$



행렬의 분해/인수화
 $\lambda = 3$ 인 경우

고유값과 고유벡터

$$(A - \lambda I)x = \begin{pmatrix} -1 & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = 0$$

$A \in \mathbb{R}^{n \times n}$ 에 대해 영벡터를 제외한 $x \in \mathbb{R}^n$ 에서
 $Ax = \lambda x$ 일 때, λ 를 고유값, x 를 고유벡터라고 함

$$x_1 - x_2 = 0, \quad x_2 = x_1, \quad x = x_1 \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$



고유값 $\lambda = 3$ 에 대한 고유벡터 : $x_1 \begin{pmatrix} 1 \\ 1 \end{pmatrix}$

$A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$ 일 때 고유값과 고유벡터를 구해보자 $(x_1 \neq 0)$

$$\det(A - \lambda I) = \begin{vmatrix} 2 - \lambda & 1 \\ 1 & 2 - \lambda \end{vmatrix} = (2 - \lambda)^2 - 1 = \lambda^2 - 4\lambda - 3 = 0$$


$\det(A - \lambda I) = 0$ 이용

$\therefore \lambda = 1 \text{ or } 3$

고유값과 선형변환

$$\begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 3 \\ 3 \end{pmatrix} \Leftrightarrow \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = 3 \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

A
 X
 λ
 X



- $Ax = \lambda x$ 는 x 의 A 에 의한 선형변환이 x 의 λ 에 의한 상수배와 같은 결과를 의미
- x 의 방향을 그대로 두고 크기만을 변화시키는 선형 변환으로 이해

양확정행렬 (Positive definite matrix)


양확정행렬

“양수를 확실히 만드는 행렬”에서 유래

$A \in \mathbb{R}^{n \times n}$, 영벡터를 제외한 임의의 $x \in \mathbb{R}^n$, $x^T A x > 0$

Example

$$A = \begin{bmatrix} 2 & 6 \\ 6 & 20 \end{bmatrix}$$



$x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$ 로 표기하면,

$$x^T A x = \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2 & 6 \\ 6 & 20 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 2x_1^2 + 12x_1x_2 + 20x_2^2$$

$$\text{이 때, } 2x_1^2 + 12x_1x_2 + 20x_2^2 = 2(x_1 + 3x_2)^2 + 2x_2^2 > 0$$

따라서 A는 양확정행렬

출레스키분해(Cholesky Decomposition)

$$\begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix} = \begin{bmatrix} l_{11} & \cdots & 0 \\ \vdots & \ddots & \vdots \\ l_{n1} & \cdots & l_{nn} \end{bmatrix} \begin{bmatrix} l_{11} & \cdots & l_{1n} \\ \vdots & \ddots & \vdots \\ 0 & \cdots & l_{nn} \end{bmatrix}$$

$A \qquad \qquad \qquad L \qquad \qquad \qquad L^T$

대칭 & 양확정 행렬인 행렬 A에 대해 다음이 성립

- 1) 0이 아닌 성분이 양수로 구성된 **하삼각 행렬 L**에 대해 $A = LL^T$ 을 만족
- 2) 이때 L은 행렬 A에 대해 유일하게 존재하며 출레스키 팩터라고 정의

출레스키 분해  **행렬식 계산을 간단화**



출레스카 분해 (Cholesky Decomposition)

$$\det(A) = \det(LL^T)$$

$$\begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix} = \det(L) \det(L^T) = \det(L)^2 \begin{bmatrix} l_{11} & \cdots & 0 \\ \vdots & & \vdots \\ l_{n1} & \cdots & l_{nn} \end{bmatrix} \begin{bmatrix} l_{11} & \cdots & l_{1n} \\ \vdots & & \vdots \\ 0 & \cdots & l_{nn} \end{bmatrix}$$

$A \qquad \qquad \qquad L \qquad \qquad \qquad L^T$

$\therefore \det(L) = \text{대각성분의 곱}$ 이므로

대칭 & 양확정 행렬인 행렬 A에 대해 다음이 성립

1) $\det(A)$ 을 대각성분의 곱으로 구할 수 있음

2) 이때 L은 행렬 A에 대해 유일하게 존재하며 출레스키 팩터라고 정의

출레스키 분해




행렬식 계산을 간단화

대각행렬이란?

대각행렬(Diagonal Matrix)

대각선에만 0이 아닌 성분이 있고,
그 외의 성분은 모두 0인 행렬


$$D = \begin{pmatrix} C_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & C_n \end{pmatrix}$$

대각행렬은 행렬식, 거듭제곱, 역행렬 계산 등에서 굉장한 이점을 지님.



대각행렬

대각화(Diagonalization)

대각행렬(Diagonal Matrix)

- 대각행렬 $D \in \mathbb{R}^{n \times n}$, 어떤 행렬 $A \in \mathbb{R}^{n \times n}$ 에 대해

$D = P^{-1}AP$ 인 역행렬이 존재하는 행렬 $P \in \mathbb{R}^{n \times n}$ 가 존재할 때,

A 를 대각화 가능(Diagonalizable)하다고 하며,

위의 과정을 **대각화**라고 함.

대각행렬은 행렬식, 거듭제곱, 역행렬 계산 등에서 굉장한 이점을 지님.

고유값 분해란?

고유값 분해(EigenDecomposition; EVD)

어떤 정사각행렬 $D \in \mathbb{R}^{n \times n}$ 에 대해
A의 고유벡터들이 \mathbb{R}^n 의 기저를 형성할 때,

$$A = PDP^{-1} \text{만들 수 있음}$$

↓

$$P \in \mathbb{R}^{n \times n} \text{이며,}$$

D는 각 대각 성분이 A의 고유값으로 구성된 대각행렬



위의 과정을 고유값 분해라고 부름

고유값 분해

고유값 분해가 이루어지는 과정

다음의 행렬을 예로 들어보자

$$A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$

고유값과 고유벡터

 $\lambda = 1$ 일 때

$$\begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

 $\lambda = 3$ 일 때

$$\begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} = \overset{P}{\begin{pmatrix} 1 & 1 \\ -1 & 1 \end{pmatrix}} \overset{D}{\begin{pmatrix} 1 & 0 \\ 0 & 3 \end{pmatrix}} \overset{P^{-1}}{\begin{pmatrix} 0.5 & -0.5 \\ 0.5 & 0.5 \end{pmatrix}}$$

4

응용편

특이값 분해의 개념

특이값 분해 (Singular Value Decomposition)

- $n \times m$ 크기의 일반적인 행렬에 대해 분해가 가능
 - 선형대수학에서 매우 중요한 분해 방법

“*Fundamental Method of Linear Algebra*”

특이값 분해의 개념

특이값 분해

- $A : m \times n$ 행렬이며 계수(rank)가 $0 \leq \text{rank}(A) \leq \min(m, n)$
 - $V^T : n \times n$ 행렬, $U : m \times m$ 행렬, $\Sigma : m \times n$ 행렬
- U 와 V 는 직교행렬이며 Σ 는 성분이 $\Sigma_{ii} \neq 0, \Sigma_{ij} = 0 (i \neq j)$ 인 행렬

$$\begin{array}{c}
 \boxed{A} \\
 m \times n
 \end{array}
 =
 \begin{array}{c}
 \boxed{U} \\
 m \times m
 \end{array}
 \times
 \begin{array}{c}
 \boxed{\Sigma} \\
 m \times n
 \end{array}
 \times
 \begin{array}{c}
 \boxed{V^T} \\
 n \times n
 \end{array}$$

특이값 분해



- 직교 행렬의 정의에 따라 $A = U\Sigma V^T = U\Sigma V^{-1}$
- Σ 는 대각 행렬을 부분집합으로 가지는 $m \times n$ 크기의 행렬, 이는 성분이 $\Sigma_{ii} \neq 0, \Sigma_{ij} = 0 (i \neq j)$ 인 행렬로 표현되기 때문임.


$$\begin{pmatrix} \sigma_1 & 0 & \cdots & 0 \\ 0 & \sigma_2 & \cdots & 0 \\ & & \ddots & \\ 0 & 0 & \cdots & \sigma_n \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \cdots & 0 \end{pmatrix}$$

$$m > n$$

$$\begin{pmatrix} \sigma_1 & 0 & \cdots & 0 & 0 & \cdots & 0 \\ 0 & \sigma_2 & \cdots & 0 & 0 & \cdots & 0 \\ & & \ddots & & & & \\ & & & \ddots & & & \\ 0 & 0 & \cdots & \sigma_m & 0 & \cdots & 0 \end{pmatrix}$$

$$m < n$$

특이값 분해의 기하학적 해석



- V^T : Domain(정의역)에서 표준 기저에서 다른 기저로 변환 (Basis Change)
- Σ : 새로운 기저에서 값 스케일링
- U : 회전(Rotation)을 통해 Codomain(공역)에서 기저 변환

특이값 분해의 활용

특이값 분해 (Singular Value Decomposition)

지금까지 다룬 특이값 분해는
특이값 분해의 기본적인 개념이며, Full SVD라고 불림.



하지만 실제로는 축약된 버전인
Reduced SVD를 더 많이 활용하는 편임.

Reduced SVD

Reduced SVD의 종류들

$$\begin{array}{c} (m \times s) \\ \boxed{A} \end{array} = \begin{array}{c} (m \times m) \\ \boxed{U} \end{array} \begin{array}{c} (m \times s) \\ \begin{array}{c} \sigma_1 \backslash \\ \sigma_s \\ 0 \end{array} \end{array} \begin{array}{c} (s \times s) \\ \boxed{V^T} \end{array}$$

<그림 2> full SVD

$$\begin{array}{c} \boxed{A} \end{array} = \begin{array}{c} (m \times s) \\ \boxed{U_s} \end{array} \begin{array}{c} (s \times s) \\ \begin{array}{c} \sigma_1 \backslash \\ \sigma_s \end{array} \end{array} \begin{array}{c} (s \times s) \\ \boxed{V^T} \end{array}$$

<그림 3> thin SVD


$$\begin{array}{c} \boxed{A} \end{array} = \begin{array}{c} (m \times r) \\ \boxed{U_r} \end{array} \begin{array}{c} (r \times r) \\ \begin{array}{c} \sigma_1 \backslash \\ \sigma_r \end{array} \end{array} \begin{array}{c} (r \times r) \\ \boxed{V_r^T} \end{array}$$

<그림 4> Compact SVD


$$\begin{array}{c} \boxed{A'} \end{array} = \begin{array}{c} (m \times t) \\ \boxed{U_t} \end{array} \begin{array}{c} (t \times t) \\ \begin{array}{c} \sigma_1 \backslash \\ \sigma_t \end{array} \end{array} \begin{array}{c} (t \times t) \\ \boxed{V_t^T} \end{array}$$

<그림 5> Truncated SVD

Reduced SVD




<그림 2> full SVD



<그림 3> thin SVD

r: 0이 아닌 값들의 개수

(m x r) (r x r) (r x r)



<그림 4> Compact SVD

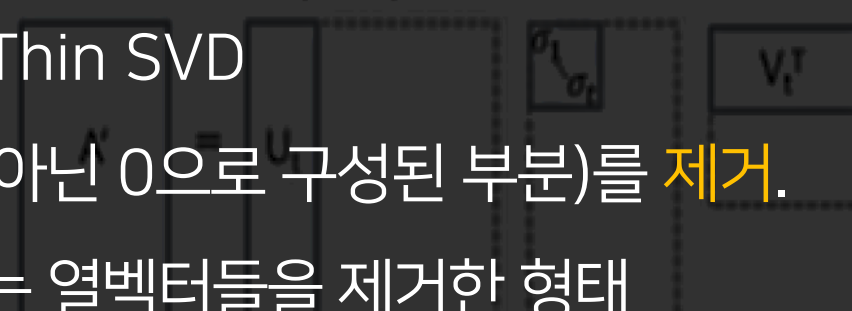
<그림3> Thin SVD

: Σ 에서 **비대각파트**(대각파트가 아닌 0으로 구성된 부분)를 제거.

또한, U에서 이에 대응되는 열벡터들을 제거한 형태

t: r보다도 더 작은 수(원본 복구 불가능)

(m x t) (t x t) (t x t)



<그림 5> Truncated SVD


Reduced SVD

<그림4> Compact SVD

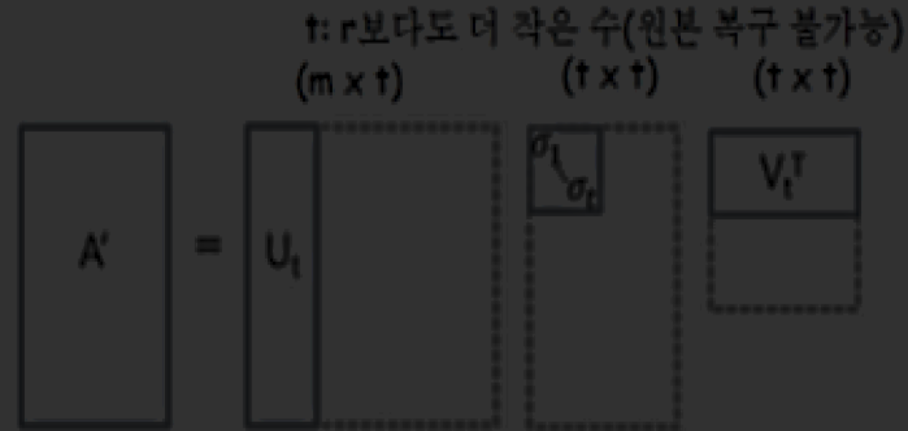
: Σ 에서 비대각파트뿐 아니라 **Singular Values** 중 0인 부분까지 제거한 형태이며, 이에 따라 U 와 V^T 를 조정한 형태

<그림 2> full SVD

<그림 3> thin SVD



<그림 4> Compact SVD




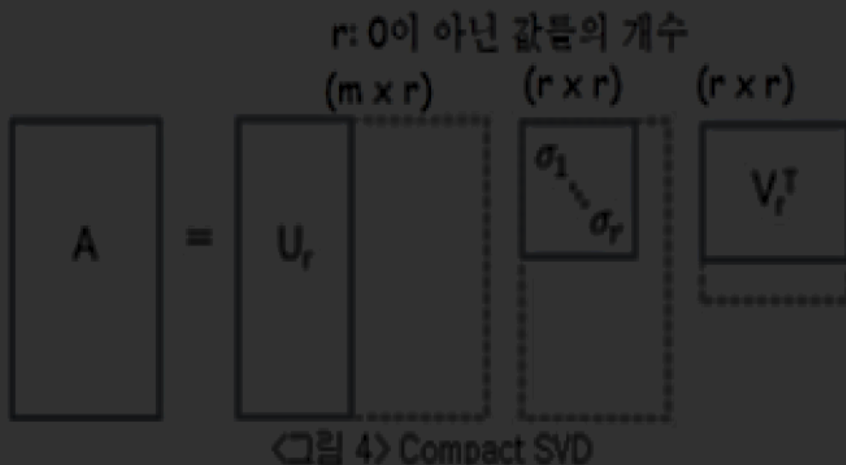
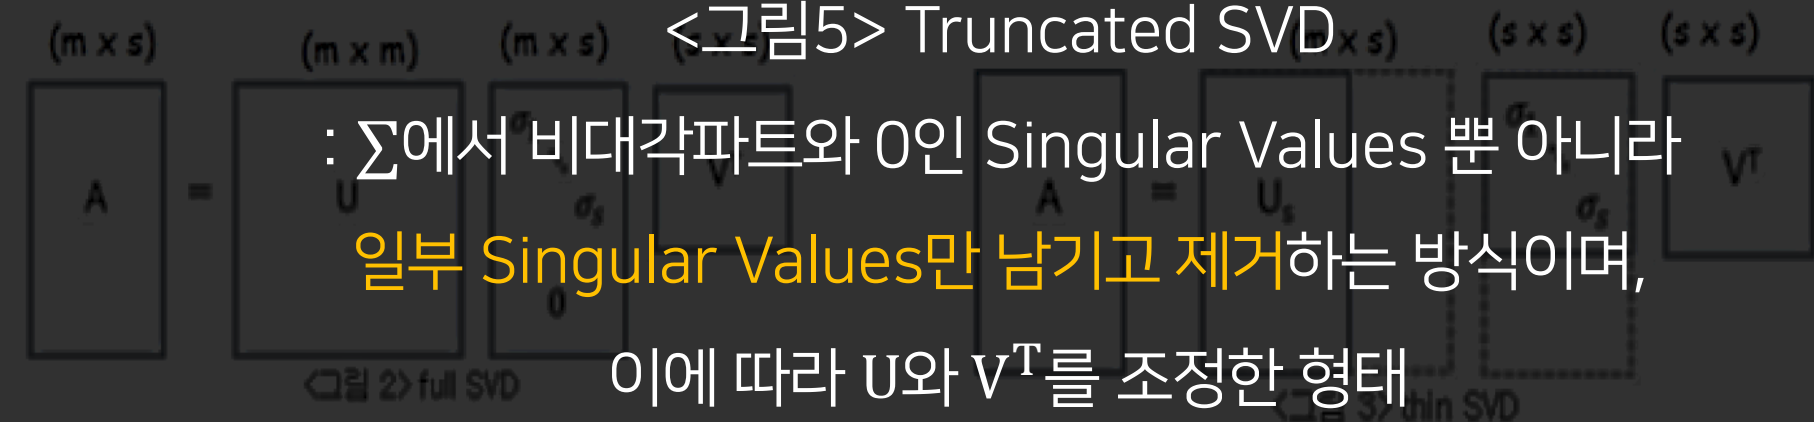
<그림 5> Truncated SVD

Reduced SVD


<그림5> Truncated SVD

: Σ 에서 비대각파트와 0인 Singular Values 뿐 아니라
 일부 Singular Values만 남기고 제거하는 방식이며,


이에 따라 U 와 V^T 를 조정한 형태




Reduced SVD



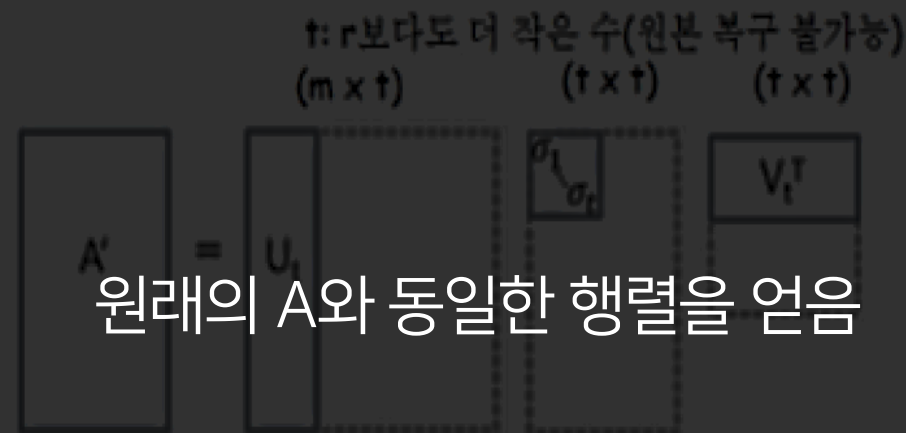
〈그림 2〉 full SVD



〈그림 3〉 thin SVD



〈그림 4〉 Compact SVD


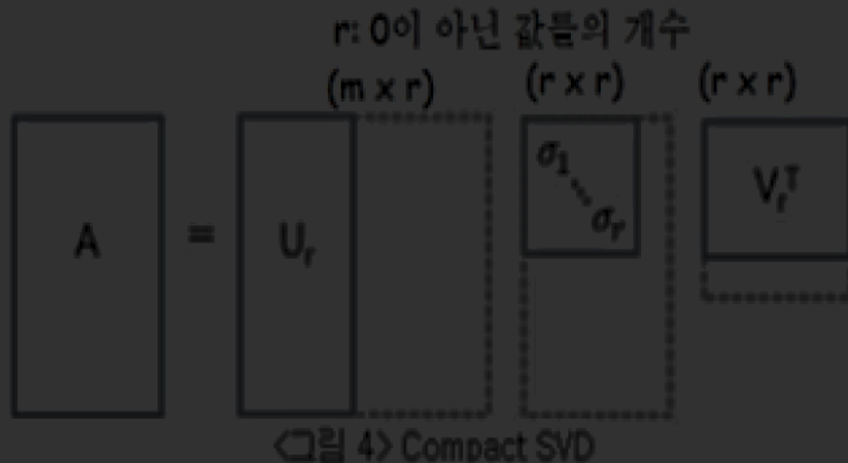
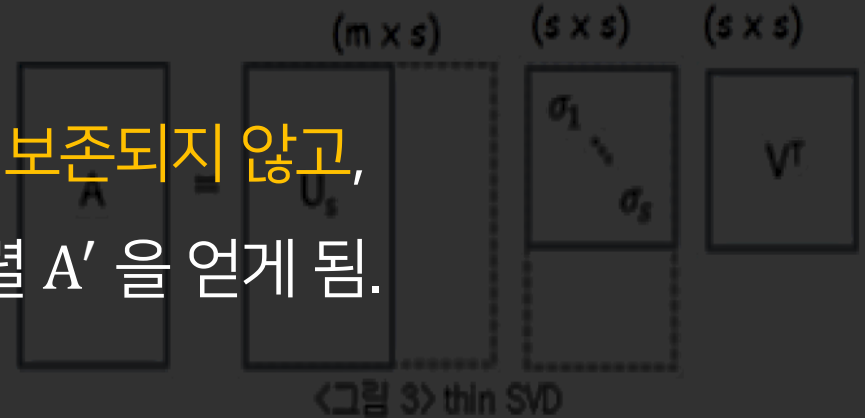
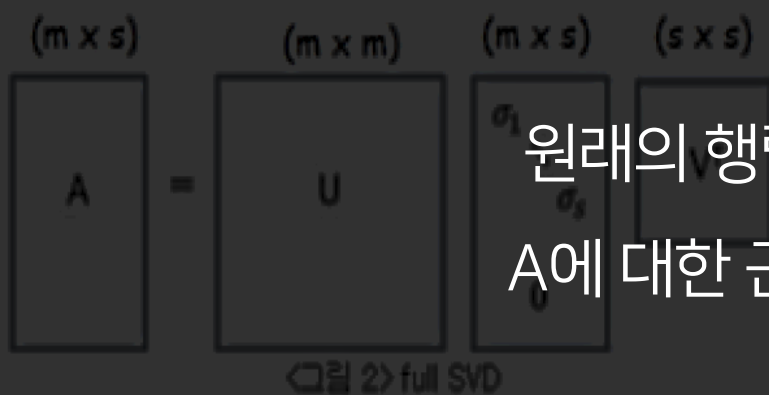


〈그림 5〉 Truncated SVD


원래의 A 와 동일한 행렬을 얻음

Reduced SVD

원래의 행렬 A 가 보존되지 않고,
 A 에 대한 근사행렬 A' 을 얻게 됨.



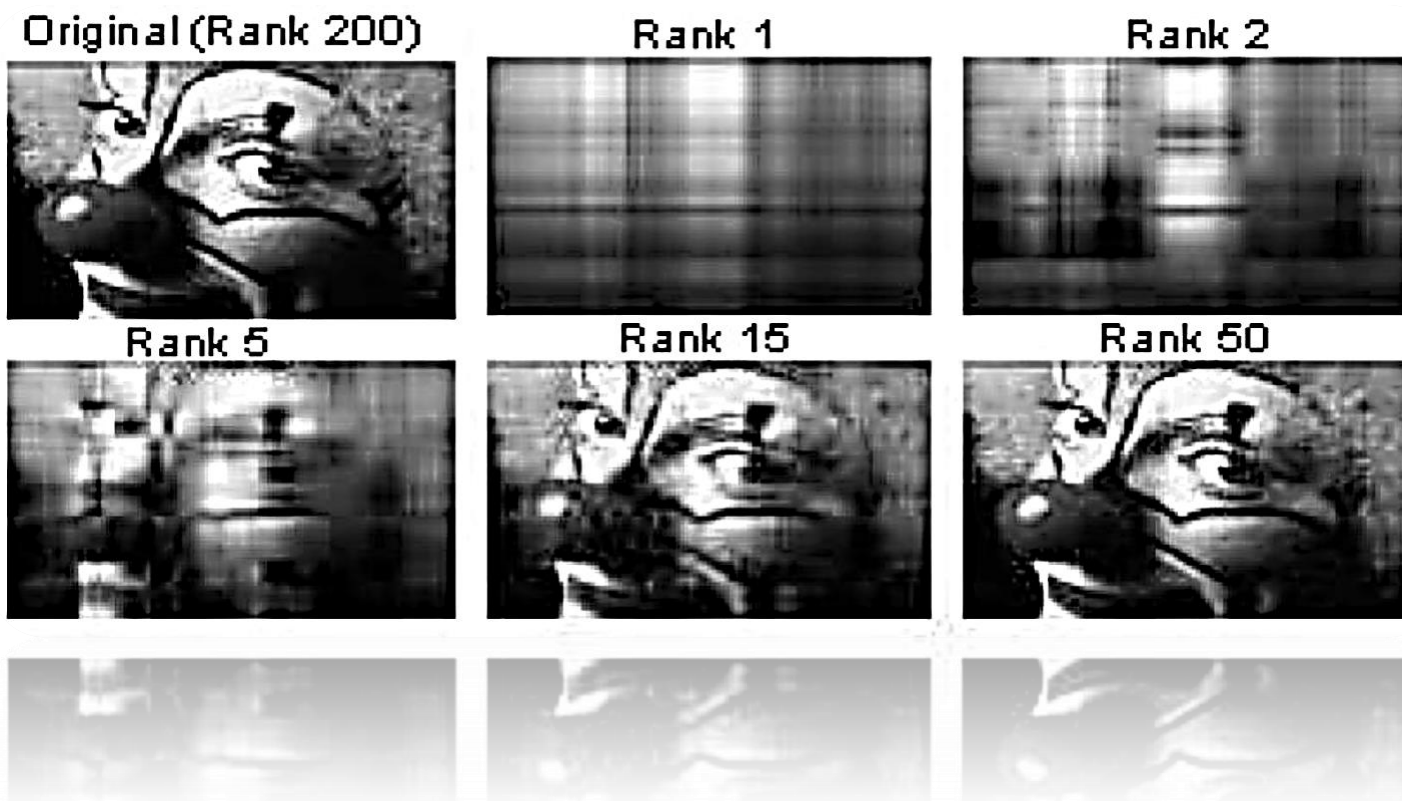
Truncated SVD



이렇게 얻게 된 A' 은 Matrix Norm $\|A - A'\|$ 을
 최소화시키는 rank t 행렬로

데이터 압축, 노이즈 제거 등에 활용됨.

Truncated SVD의 활용



Rank 50으로도 충분히 Original 그림을 나타낼 수 있는 이점이 있음.

Truncated SVD의 활용



Truncated SVD의 중요 포인트

이미지 데이터에서 중요한 부분(일부 Singular Values)만을 남기고 필요 없는 정보를 제거함으로써

I. 정보량을 줄이고

II. 용량과 연산량을 줄이는 것이 중요 포인트!

→ 이미지 분석에서 *더 적은 정보로 효율적이고 빠른 분석 가능*



Rank 50으로도 충분히 Original 그림을 나타낼 수 있는 이점이 있음.

다음 주 예고

1. 벡터 미적분학
2. 최적화
3. 주성분 분석