

선형대수학팀

3팀
이재현
김규범
김민지
이정우
조혜현

INDEX

1. 주성분 분석(PCA)
2. 벡터 미적분학
3. 벡터 미적분학의 응용

1

주성분 분석(PCA)

차원의 저주 & 차원의 축소

차원

설명변수의 개수

Input 데이터에서 X 변수의 개수

차원 증가



X 변수가 늘어남



데이터를 더욱 잘 설명

차원의 저주 & 차원의 축소

차원

차원이 높으면 항상 좋은 걸까?

Input 데이터에서 X 변수의 개수

차원 증가

 X 변수가 늘어남

차원의 저주 & 차원의 축소

차원

설명 변수의 개수
No!

Input 데이터에서 변수의 개수

차원 증가

“ 차원의 저주 ”

X변수가 늘어남

데이터를 더욱 잘 설명

차원의 저주 & 차원의 축소

차원의 저주

차원이 어느 정도 이상 증가하면
성능이 저하되는 현상

 연산량 증가 ➡ 데이터의 학습 속도 저하

 데이터의 밀도 감소 ➡ 성능 저하

차원의 저주 & 차원의 축소

차원의 저주

차원이 어느 정도 이상 증가하면
성능이 저하되는 현상



차원 증가 ➡ 밀도 줄어들어 성능 저하

차원의 저주



공분산에 대한 선형대수에서의 해석

공분산

두 확률변수의 선형관계에 대한 정보를 주는 척도

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y)$$

$X = [x_1 \ x_2 \ \cdots \ x_n]^T$ 으로 구성된 행렬이며, x_i 가 각각 벡터일 때,

$$\text{공분산 행렬 } K_{XX} = \begin{bmatrix} \text{Cov}(X_1, X_1) & \text{Cov}(X_1, X_2) & \cdots & \text{Cov}(X_1, X_n) \\ \text{Cov}(X_2, X_1) & \text{Cov}(X_2, X_2) & \cdots & \text{Cov}(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_n, X_1) & \text{Cov}(X_n, X_2) & \cdots & \text{Cov}(X_n, X_n) \end{bmatrix}$$

$$= V(X_n)$$

공분산에 대한 선형대수에서의 해석

공분산 행렬을 통한 선형변환

$$\begin{bmatrix} V(X) & Cov(X, Y) \\ Cov(Y, X) & V(Y) \end{bmatrix}$$

분산 = 변수들이 퍼져 있는 정도

공분산 = 변수들의 공동적 움직임

공분산에 대한 선형대수에서의 해석

공분산 행렬을 통한 선형변환

$$\begin{bmatrix} V(X) & Cov(X, Y) \\ Cov(Y, X) & V(Y) \end{bmatrix}$$

분산 = 변수들이 퍼져 있는 정도
공분산 = 변수들의 공동적 움직임



분산과 공분산만큼
공간이 변화

변수 간의 연관성
설명

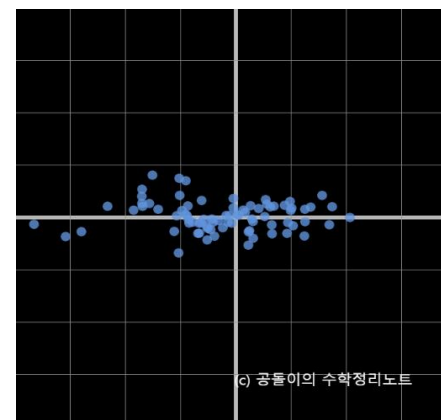


변수들이 어떻게
분포됐는지 표현

공분산에 대한 선형대수에서의 해석

공분산 행렬을 통한 선형변환

$$\begin{bmatrix} V(X) & Cov(X, Y) \\ Cov(Y, X) & V(Y) \end{bmatrix}$$

분산 = 변수들이 퍼져 있는 정도
공분산 = 변수들의 공동적 움직임

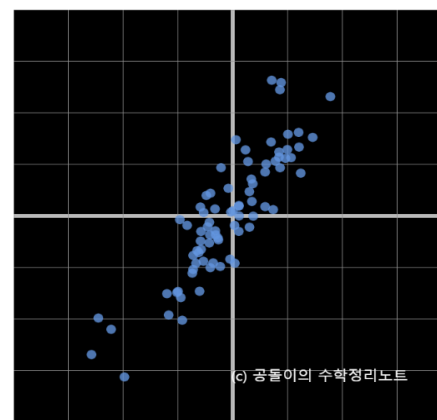




공분산에 대한 선형대수에서의 해석

공분산 행렬을 통한 선형변환

$$\begin{bmatrix} V(X) & Cov(X, Y) \\ Cov(Y, X) & V(Y) \end{bmatrix}$$


분산 = 변수들이 퍼져 있는 정도
공분산 = 변수들의 공동적 움직임



주성분 분석 (PCA)

주성분 분석

데이터를 가장 잘 설명하는 주성분을 찾아 주성분이 이루는
공간으로 데이터를 정사영시켜 차원을 축소




PC_1 이 PC_2 보다 데이터가
더 많이 퍼져 있음

~~분산이 더 큰 주성분을 선택~~

주성분 찾기

How?

공분산행렬 { 고유벡터 = PC
 고유값 = 중요성, 데이터가 퍼져 있는 정도



x 의 방향을 그대로 두고

크기만을 변화시키는 선형 변환

- 고유벡터 → 선형변환의 고정된 축
- 고유값 → 크기 변화 정도

주성분 찾기

How?

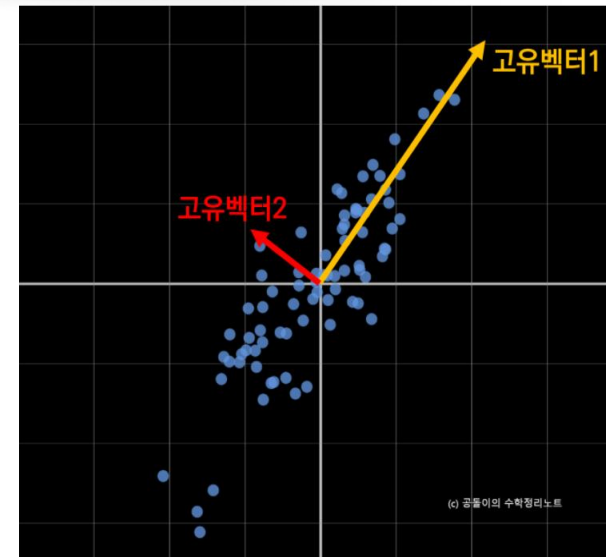
공분산행렬 { 고유벡터 = PC
 고유값 = 중요성, 데이터가 퍼져 있는 정도

공분산 행렬 $\begin{bmatrix} 3 & 2 \\ 2 & 4 \end{bmatrix}$

고유값 5.56 1.44

고유벡터 $\begin{pmatrix} 0.62 \\ 0.78 \end{pmatrix}$ $\begin{pmatrix} -0.78 \\ 0.62 \end{pmatrix}$

고유벡터1 고유벡터2






주성분

고유벡터1의 고유값은 5.56으로 고유벡터2보다
많은 데이터에 대해 분포

✓ 공분산 행렬 $\begin{bmatrix} \text{고유벡터} = \text{PC} \\ \text{고유값} = \text{중요성, 데이터가 퍼져 있는 정도} \end{bmatrix}$
고유벡터1이 고유벡터2보다 더 중요!!

공분산 행렬	$\begin{bmatrix} 3 & 2 \\ 2 & 4 \end{bmatrix}$
고유값	5.56 1.44
고유벡터	$\begin{pmatrix} 0.62 \\ 0.78 \end{pmatrix}$ $\begin{pmatrix} -0.78 \\ 0.62 \end{pmatrix}$
	고유벡터1 고유벡터2



주성분 선택



PCA결과의 설명되는 누적 분산량을 근거로 주성분의 개수 선택

	PC1	PC2	PC3	PC4
Standard Deviation	2.3925	0.44457	0.2522	0.0892
Proportion of Variance	0.8548	0.03294	0.0106	0.0034
Cumulative Proportion	0.8548	0.91273	0.9883	1.0000

누적비율로 데이터의 변동을 얼마나 설명하는지 파악 가능

주성분 선택



PCA결과의 설명되는 누적 분산량을 근거로 주성분의 개수 선택

	PC1	PC2	PC3	PC4
Standard Deviation	2.3925	0.44457	0.2522	0.0892
Proportion of Variance	0.8548	0.03294	0.0106	0.0034
Cumulative Proportion	0.8548	0.91273	0.9883	1.0000

일반적으로, 누적비율이 90%이상 되도록 선택

4차원 데이터 ➡ 2차원 데이터

2

벡터 미적분학

편미분의 개념

편미분 (Partial Differentiation)

- 어떤 다변수함수에 대해 **하나의 변수**에 주목
나머지 변수의 값 고정시켜 놓고 **그 변수로 미분**
- 다변수함수에서 1개의 변수 값이 변화할 때의
변화율을 알기 위해 사용됨
- 편미분 기호로는 ∂ 를 사용

➡ $f(x, y)$ 가 있을때 y 를 상수로 보고
이것을 x 로 미분하는 일을 " **x 로 편미분한다**"고 함

편미분 수식

$$\frac{\partial f}{\partial x_1} = \lim_{h \rightarrow 0} \frac{f(x_1 + h, x_2, \dots, x_n) - f(x)}{h}$$

$$\frac{\partial f}{\partial x_2} = \lim_{h \rightarrow 0} \frac{f(x_1, x_2 + h, \dots, x_n) - f(x)}{h}$$

$$\vdots$$

$$\frac{\partial f}{\partial x_n} = \lim_{h \rightarrow 0} \frac{f(x_1, x_2, \dots, x_n + h) - f(x)}{h}$$

하나의 변수에 주목한다는 점 제외하고는
일반적인 미분 정의와 동일

편미분 수식



편미분 계산

$$\frac{\partial f}{\partial x_1} = \lim_{h \rightarrow 0} \frac{f(x_1 + h, x_2, \dots, x_n) - f(x)}{h}$$

미분하는 변수 외에 다른 변수는 상수 취급하고

$$\frac{\partial f}{\partial x_2} = \lim_{h \rightarrow 0} \frac{f(x_1, x_2 + h, x_3, \dots, x_n) - f(x)}{h}$$

미분을 진행함

$$\vdots$$

$$\frac{\partial f}{\partial x_n} = \lim_{h \rightarrow 0} \frac{f(x_1, x_2, \dots, x_n + h) - f(x)}{h}$$

$$\frac{\partial f}{\partial x} = 2x + y$$

하나의 변수에 주목한다는 점 제외하고는

일반적인 미분 정의와 동일

미분과 Chain Rule

Case

다변수함수 f 를 구성하는 $x, y, z \dots$ 가 다시 다른 변수 t 에 대해 정의되어 있음



변수 t 에 대한 f 의 도함수는 편미분을 사용해 다음과 같이 정의

$x(t), y(t), z(t) \dots$

$$\frac{df(x, y, z, \dots)}{dt} = \frac{\partial f}{\partial x} \frac{\partial x}{\partial t} + \frac{\partial f}{\partial y} \frac{\partial y}{\partial t} + \frac{\partial f}{\partial z} \frac{\partial z}{\partial t} + \dots$$

미분과 Chain Rule

각각의 항에

다변수함수 f 를 구성하는 $x, y, z \dots$ 가 다시 다른 변수 t 에 대해 정의되어 있음

"Chain Rule" 적용

변수 t 에 대한 f 의 도함수는 편미분을 사용해 다음과 같이 정의

$(x(t), y(t), z(t), \dots)$

$$\frac{df(x, y, z, \dots)}{dt} = \boxed{\frac{\partial f}{\partial x} \frac{\partial x}{\partial t}} + \boxed{\frac{\partial f}{\partial y} \frac{\partial y}{\partial t}} + \boxed{\frac{\partial f}{\partial z} \frac{\partial z}{\partial t}} + \dots$$

미분과 Chain Rule

$$\frac{df}{dt} = \begin{bmatrix} \frac{\partial f}{\partial x_1} & \frac{\partial f}{\partial x_2} \end{bmatrix} \begin{bmatrix} \frac{\partial x_1(t)}{\partial t} \\ \frac{\partial x_2(t)}{\partial t} \end{bmatrix} = \frac{\partial f}{\partial x_1} \frac{\partial x_1}{\partial t} + \frac{\partial f}{\partial x_2} \frac{\partial x_2}{\partial t}$$



함수 f 가 $x_1(t)$, $x_2(t)$ 로 구성되어 있을 때, t 에 관한 f 의 도함수 f 를 구성하는 x_1 , x_2 가 한 개의 변수 t 로 이루어졌을 때의 예

미분과 Chain Rule

$$\frac{\partial f}{\partial s} = \frac{\partial f}{\partial x_1} \frac{\partial x_1}{\partial s} + \frac{\partial f}{\partial x_2} \frac{\partial x_2}{\partial s}$$

$$\frac{\partial f}{\partial t} = \frac{\partial f}{\partial x_1} \frac{\partial x_1}{\partial t} + \frac{\partial f}{\partial x_2} \frac{\partial x_2}{\partial t}$$



함수 f 가 $x_1(s, t)$, $x_2(s, t)$ 로 구성되어 있을 때,
 s, t 에 대한 f 의 도함수

미분과 Chain Rule

앞선 도함수를 행렬로 정리하면,

$$\begin{bmatrix} \frac{\partial f}{\partial s} & \frac{\partial f}{\partial t} \end{bmatrix} = \begin{bmatrix} \frac{\partial f}{\partial x_1} & \frac{\partial f}{\partial x_2} \end{bmatrix} \begin{bmatrix} \frac{\partial x_1}{\partial s} & \frac{\partial x_1}{\partial t} \\ \frac{\partial x_2}{\partial s} & \frac{\partial x_2}{\partial t} \end{bmatrix}$$

$\frac{\partial f}{\partial \vec{x}}$
 $\frac{\partial f}{\partial (s, t)}$

$$\begin{bmatrix} \frac{\partial f}{\partial s} & \frac{\partial f}{\partial t} \end{bmatrix} = \frac{\partial f}{\partial \vec{x}} \frac{\partial f}{\partial (s, t)}$$

Gradient란?

Gradient

- 어떤 함수 f 가 다중 변수 x_1, x_2, x_3, \dots 로 구성되어 있을 때,
- f 의 gradient 각 변수에 대하여 f 를 편미분 한 것을
행(또는 열)으로 나열한 것으로 표현
- 이때, gradient는 ∇f 혹은 $grad\ f$ 로 표기

Gradient란?



Gradient

x_1, x_2, x_3, \dots 로 구성된 어떤 함수 f 의 gradient

① 어떤 함수 f 가 다중 변수 x_1, x_2, x_3, \dots 로 구성되어 있을 때,

② f 의 gradient 각 변수에 대하여 f 를 편미분 한 것을

$$\nabla f = \text{grad } f = \left[\frac{\partial f}{\partial x_1} \quad \frac{\partial f}{\partial x_2} \quad \frac{\partial f}{\partial x_3} \quad \dots \right]$$

③ 이때, gradient는 ∇f 혹은 $\text{grad } f$ 로 표기

Gradient란?



Gradient

어떤 스칼라 함수 f 에 대해서

어떤 함수 f 가 다중 변수 x_1, x_2, \dots, x_n 에 의존되어 있을 때,
 gradient ∇f 의 방향은

f 의 gradient 각 변수에 대하여 f 를 편미분 한 것을
 f 가 가장 빨리 증가하는
 행(또는 열)으로 나열한 것으로 표현

이때, gradient ∇f 를 $grad f$ 로 표기

Gradient란?



Gradient

f 에 대한 등고선을 그렸을 때, 각 등고선에서 어떤 지점의 접선이

그 지점에서의 gradient와 반드시 수직을 이루게 됨



어떤 함수 f 가 n 개 변수 x_1, x_2, x_3, \dots 로 구성되어 있을 때,

f 의 gradient 각 변수에 대하여 f 를 편미분 한 것을

3차원 이상으로 확장했을 때,

한 점에서의 gradient는 그 점에서의 접평면과 수직을 이루게 됨

등고선과 Gradient



어떤 함수 f 의 등고선과 gradient는 **수직**
즉, **접선**을 이루는 모습

직교 관계 증명

🐱 $w = f(x, y, z)$ 라는 3변수 함수가 있다고 하자.

등고선: 어떤 함수에 대해 함수 값이
동일한 것을 모아 선으로 그려 놓은 것

등고선을 구하기 위한 어떤 level c 에 대한 교점의 집합

$$f(x, y, z) = c \text{ (} c \text{는 상수)}$$

🌀 *"Level Surface"*



직교 관계 증명



어떤 특정 Level Surface 값(이하 c)에 대한 함수를 살펴보자.

값이 c 인 Level surface 위의 점들을 모아 놓은
 curve를 $\underline{r(t) = \langle x(t), y(t), z(t) \rangle}$ 라 하고,
 $g(t) = f(x(t), y(t), z(t)) = c$ 라 하자.



즉, r 은 값이 c 를 가리키는 어떤 등고선 위의 점들을 나타낸 일종의 함수

직교 관계 증명

 $g(t) = c$ 를 양변에 대해 미분하게 되면,

Chain Rule에 의해


$$\frac{dg}{dt} = \frac{\partial f}{\partial x} \frac{dx}{dt} + \frac{\partial f}{\partial y} \frac{dy}{dt} + \frac{\partial f}{\partial z} \frac{dz}{dt} = 0$$



Vector Form으로 정리하면

$$\left\langle \frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}, \frac{\partial f}{\partial z} \right\rangle \cdot \left\langle \frac{dx}{dt}, \frac{dy}{dt}, \frac{dz}{dt} \right\rangle = 0$$

직교 관계 증명

 앞선 식의 표현을 바꿔보면,


$$\nabla f \cdot \underline{r'(t)} = 0$$

c 에서의 Level surface 위의 curve를 뜻하는
함수 r 의 접선 기울기



등고선에서의 **접선의 기울기**

직교 관계 증명

 앞선 식의 표현을 바꿔보면,


$$\nabla f \cdot \underline{r'(t)} = 0$$

f 의 gradient와 등고선에서의 접선의 기울기의
내적 값이 **0**이 되는 것



f 의 gradient와 등고선의 접선은 **직교** 관계를 이룸

직교 관계 증명



“

등고선의 접선과 f 의 gradient가 **직교**를 이룬다는 말은
 특정 점에서 **가장 크게 증가하는 방향**으로 기울기 벡터의 방향이 설정된다는 것!

”

벡터함수란?

벡터함수
(Vector-Valued Functions)

$f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 과 벡터 $\mathbf{x} = [x_1, x_2, \dots, x_n]^T$ 로 주어졌다고 할 때,

$$\mathbf{f}(\mathbf{x}) = \begin{bmatrix} f_1(x) \\ \vdots \\ f_m(x) \end{bmatrix} \in \mathbb{R}^m \text{으로 정의}$$


벡터함수란?

벡터함수
(Vector-Valued Functions)

\mathbf{f} 는 함수 f_1, f_2, \dots, f_m 들의 벡터로 $\begin{bmatrix} f_1 \\ \vdots \\ f_m \end{bmatrix}$ 로 표현되며

각 f_i 는 $f_i: \mathbb{R}^n \rightarrow \mathbb{R}$ 로 일반적인 실수 함수


벡터함수의 Gradient

 실수함수 f_1, f_2, \dots 에 대해 $f = \begin{bmatrix} f_1 \\ \vdots \\ f_m \end{bmatrix}$, 벡터 $x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$ 로 주어졌다고 하자.

벡터함수 f 를 특정 x_i 에 대해 편미분하면

$$\frac{\partial f}{\partial x_i} = \begin{bmatrix} \frac{\partial f_1}{\partial x_i} \\ \vdots \\ \frac{\partial f_m}{\partial x_i} \end{bmatrix}$$

벡터함수의 Gradient

 실수함수 f_1, f_2, \dots 에 대해 $f = \begin{bmatrix} f_1 \\ \vdots \\ f_m \end{bmatrix}$, 벡터 $x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$ 로 주어졌다고 하자.

벡터함수 f 를 벡터 x 에 대해 편미분하면

$$\frac{\partial f(x)}{\partial x} = \left[\frac{\partial f(x)}{\partial x_1} \quad \cdots \quad \frac{\partial f(x)}{\partial x_n} \right]$$

벡터함수의 Gradient



앞선 식은 최종적으로 다음과 같이 전개됨

$$\frac{\partial f(x)}{\partial x} = \left[\frac{\partial f(x)}{\partial x_1} \quad \dots \quad \frac{\partial f(x)}{\partial x_n} \right] = \begin{bmatrix} \frac{\partial f_1(x)}{\partial x_1} & \dots & \frac{\partial f_1(x)}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_m(x)}{\partial x_1} & \dots & \frac{\partial f_m(x)}{\partial x_n} \end{bmatrix}$$

바로 위의 식을 벡터함수 f 의 gradient라고 정의하며,

$\nabla_x f$ 로 표기


3

벡터 미적분학의 응용

자코비안(Jacobian)

자코비안

벡터함수 F 의 gradient
기하학적으로 **축 변환**의 역할을 수행




자코비안(Jacobian)




자코비안의 수식

벡터함수 F 의 gradient

$$J = \nabla_x \mathbf{f} = \frac{\partial \mathbf{f}(x)}{\partial x} = \begin{bmatrix} \frac{\partial f_1(x)}{\partial x_1} & \cdots & \frac{\partial f_1(x)}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_m(x)}{\partial x_1} & \cdots & \frac{\partial f_m(x)}{\partial x_n} \end{bmatrix}$$



$$= \begin{bmatrix} \frac{\partial f_1(x)}{\partial x_1} & \cdots & \frac{\partial f_1(x)}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_m(x)}{\partial x_1} & \cdots & \frac{\partial f_m(x)}{\partial x_n} \end{bmatrix}$$



$$A \in \mathbb{R}^{n \times n}$$

자코비안(Jacobian)



Example

$$x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, y = \begin{bmatrix} y_1 \\ y_2 \end{bmatrix}$$

x 에서 y 로의 축 변환



$y_1 = -2x_1 + x_2, y_2 = x_1 + x_2$ 의 관계를 가정

$$J = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \frac{\partial y_1}{\partial x_2} \\ \frac{\partial y_2}{\partial x_1} & \frac{\partial y_2}{\partial x_2} \end{bmatrix} = \begin{bmatrix} -2 & 1 \\ 1 & 1 \end{bmatrix} \text{를 } x \text{에 곱함으로써 } y \text{로 축 변환을 수행}$$


$$x = (1, 1) \text{ 은 } \begin{bmatrix} -2 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} -1 \\ 2 \end{bmatrix} \text{ 이므로 } y = (-1, 2) \text{로 변환됨}$$

자코비안의 활용



수리통계학에서 축 변환을 위해 자코비안 행렬의 **행렬식** 사용
 자코비안의 행렬식은 **좌표축을 변환시켰을 때의 크기 변화**를 의미

$$f_{y_1, y_2}(y_1, y_2) = |J| f_{x_1, x_2}(g(y_1, y_2), h(y_1, y_2))$$




자코비안의 활용



수리통계학에서 축 변환을 위해 자코비안 행렬의 **행렬식** 사용
 자코비안의 행렬식은 **좌표축을 변환시켰을 때의 크기 변화**를 의미

$$f_{y_1, y_2}(y_1, y_2) = |J| f_{x_1, x_2}(g(y_1, y_2), h(y_1, y_2))$$



X의 pdf를 통해 Y의 pdf를 구해보자

독립변수 X_1, X_2 에 대해 $Y_1 = X_1, Y_2 = X_1 + X_2$ 일 때,


$$J = \begin{bmatrix} \frac{\partial x_1}{\partial y_1} & \frac{\partial x_1}{\partial y_2} \\ \frac{\partial x_2}{\partial y_1} & \frac{\partial x_2}{\partial y_2} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ -1 & 1 \end{bmatrix} \text{이 되|어, } |J| = \begin{vmatrix} \frac{\partial x_1}{\partial y_1} & \frac{\partial x_1}{\partial y_2} \\ \frac{\partial x_2}{\partial y_1} & \frac{\partial x_2}{\partial y_2} \end{vmatrix} = \begin{vmatrix} 1 & 0 \\ -1 & 1 \end{vmatrix} = \mathbf{1}$$

자코비안의 활용



수리통계학에서 축 변환을 위해 자코비안 행렬의 **행렬식** 사용
 자코비안의 행렬식은 **좌표축을 변환시켰을 때의 크기 변화**를 의미

$$f_{y_1, y_2}(y_1, y_2) = |J| f_{x_1, x_2}(g(y_1, y_2), h(y_1, y_2))$$



X의 pdf를 통해 Y의 pdf를 구해보자

독립변수 X_1, X_2 에 대해 $Y_1 = X_1, Y_2 = X_1 + X_2$ 일 때,


$f_{y_1, y_2}(y_1, y_2) = |J| f_{x_1, x_2}(g(y_1, y_2), h(y_1, y_2))$ 식에 대입

$$f_{y_1, y_2}(y_1, y_2) = |J| f_{x_1, x_2}(y_1, -y_1 + y_2) = f_{x_1, x_2}(y_1, -y_1 + y_2)$$

Back Propagation

Back Propagation

Back Propagation(역전파) 과정에서 각 파라미터에 대한 gradient를 구하게 됨



Back Propagation

Back Propagation

Back Propagation(역전파) 과정에서 라미닥에 대한 gradient를 구하게 됨




자세한 내용은

✓ **딥러닝팀 1주차 교안** 참고!



Back Propagation




*은 행렬의 곱 연산, $L2$ 는 Input 값을 제공하는 함수를 의미

*을 이용해 연산하는 중간 결과 식 $q = W \cdot x$

최종 결과 식 $f(x, W) = ||W \cdot x||^2 = \sum_{i=1}^n (W \cdot x)_i^2$

역전파 과정에서 $\nabla_W f, \nabla_x f, \nabla_q f$ 를 구하게 됨

Back Propagation




1) $\nabla_q f$ 구하기

$$f(q) = \|q\|^2 = q_1^2 + q_2^2 + \dots + q_n^2 \text{ 이므로 } \frac{\partial f}{\partial q_i} = 2q_i$$

즉, 모든 i 에 대해서 위의 등식이 성립하므로 $\nabla_q f = 2q$

$$\text{따라서, } q \text{가 } \begin{bmatrix} 0.22 \\ 0.26 \end{bmatrix} \text{일 때, } \nabla_q f = \begin{bmatrix} 0.44 \\ 0.52 \end{bmatrix}$$

Back Propagation




2) $\nabla_w f$ 구하기

$$\frac{\partial f}{\partial W_{ij}} = \sum_k \frac{\partial f}{\partial q_k} \cdot \frac{\partial q_k}{\partial W_{ij}} \quad \text{여기서 } q = W \cdot x \quad \text{이므로 } \frac{\partial q_k}{\partial W_{ij}} = 1_{k=i} x_j$$

$$(\because q = W \cdot x = \begin{bmatrix} W_{1,1}x_1 + \cdots + W_{1,n}x_n \\ \vdots \\ W_{n,1}x_1 + \cdots + W_{n,n}x_n \end{bmatrix})$$

Back Propagation




2) $\nabla_w f$ 구하기

따라서, $\frac{\partial f}{\partial W_{ij}} = \sum_k \frac{\partial f}{\partial q_k} \cdot \frac{\partial q_k}{\partial W_{ij}} = \sum_k 2q_k \cdot (1_{k=i}x_j) = 2q_i x_j$ 이므로 $\nabla_w f = 2q \cdot x^T$

즉, q 와 x 가 각각 $\begin{bmatrix} 0.22 \\ 0.26 \end{bmatrix}$, $\begin{bmatrix} 0.2 \\ 0.4 \end{bmatrix}$ 로 주어졌을 때

$$\nabla_w f = \begin{bmatrix} 0.44 \\ 0.52 \end{bmatrix} \begin{bmatrix} 0.2 & 0.4 \end{bmatrix} = \begin{bmatrix} 0.088 & 0.176 \\ 0.104 & 0.208 \end{bmatrix}$$

Back Propagation




3) $\nabla_x f$ 구하기

$$\frac{\partial f}{\partial x_i} = \sum_k \frac{\partial f}{\partial q_k} \cdot \frac{\partial q_k}{\partial x_i} \quad \text{여기서 } q = W \cdot x \quad \text{이므로 } \frac{\partial q_k}{\partial x_i} = W_{k,i}$$

$$(\because q = W \cdot x = \begin{bmatrix} W_{1,1}x_1 + \cdots + W_{1,n}x_n \\ \vdots \\ W_{n,1}x_1 + \cdots + W_{n,n}x_n \end{bmatrix})$$

Back Propagation



3) $\nabla_x f$ 구하기

따라서, $\frac{\partial f}{\partial x_i} = \sum_k \frac{\partial f}{\partial q_k} \cdot \frac{\partial q_k}{\partial x_i} = \sum_k 2q_k \cdot W_{k,i}$ 이므로 $\nabla_x f = 2W^T \cdot q$


즉, q 와 W 가 각각 $\begin{bmatrix} 0.22 \\ 0.26 \end{bmatrix}$, $\begin{bmatrix} 0.1 & 0.5 \\ -0.3 & 0.8 \end{bmatrix}$ 로 주어졌을 때,

$$\nabla_x f = \begin{bmatrix} 0.2 & -0.6 \\ 1.0 & 0.8 \end{bmatrix} \begin{bmatrix} 0.22 \\ 0.26 \end{bmatrix} = \begin{bmatrix} -0.112 \\ 0.636 \end{bmatrix}$$

Gradient Descent

Gradient Ascent


등고선에서 가장 빠르게 **증가**하는 방향으로 이동
gradient가 가리키는 방향으로 움직여 최대값을 찾는 과정



Gradient Descent

Gradient Descent

등고선에서 가장 빠르게 감소하는 방향으로 이동
Loss값을 최소화하기 위해 gradient에 (-1) 을 곱해서 알고리즘 운영




Gradient Descent

Gradient Descent



등고선에서 가장 빠른 ∇f 을 찾는 방향으로 이동
Loss값을 최소화하기 위해 그라디언트에 (-1) 을 곱해서 알고리즘 운영


gradient 벡터에 반대방향으로 나아가다 보면
최소값에 도달하게 될 것이라는 발상에서 출발



Gradient Descent

Gradient Descent

등고선에서 가장 빠르게 감소하는 방향으로 이동
Loss값을 최소화하기 위해 gradient에 (-1) 을 곱해서 알고리즘 운영



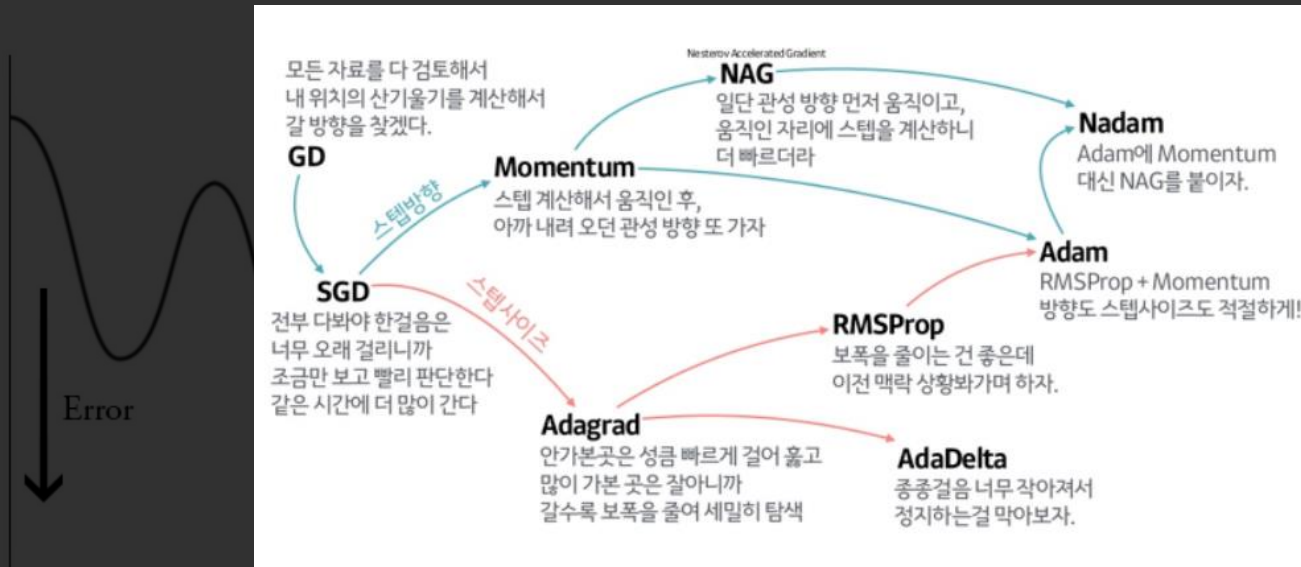
gradient의 값이
0이 되는 지점에서 멈춤
→ 하지만 Gradient Descent 방법은
local minimum에 빠질 수 있고
속도가 느리다는 단점 존재



Gradient Descent의 단점을

보완하기 위해 **다양한 Optimizer**가 등장

등고선에서 가장 빠르게 감소하는 방향으로 이동
 ✓ **딥러닝팀 1주차 교안 참고!**
 Loss값을 최소화하기 위해 그라디언트에 (-1) 를 곱해서 알고리즘 운영



Thank You

